

一、实验目的

1. 掌握传统机器学习方法在图像分类任务中的应用流程，包括数据加载、预处理、模型训练与评估。
2. 对比不同分类模型（KNN、朴素贝叶斯、逻辑回归、SVM、决策树、随机森林）在手写数字识别任务中的性能差异。
3. 学习使用混淆矩阵、错误样本分析等方法，评估模型的分类效果并分析误差来源。
4. 理解图像数据的原始像素特征表示方法及其优缺点

二、实验环境与数据集

1. 实验环境

操作系统：Windows 11 + WSL Ubuntu

开发工具：VS Code

编程语言：Python 3.12

主要依赖库：scikit-learn、OpenCV、matplotlib、numpy

2. 数据集说明

本次实验使用 scikit-learn 内置的 **Digits 手写数字数据集**，该数据集包含：


样本总数：1797 张 8×8 灰度图像

类别：0~9 共 10 类手写数字

特征表示：每张图像展平为 64 维向量，对应 8×8 像素值

数据划分：按 75% 训练集、25% 测试集进行划分

部分样本示例如下图所示：



三、实验原理与方法

1. 数据预处理

将 8×8 的灰度图像按行展平为 64 维向量，作为模型的输入特征，同时将数据集划分为训练集和测试集，其中训练集用于模型学习，测试集用于评估模型的泛化能力。

2. 分类模型介绍

本次实验对比了 6 种不同的传统机器学习分类器：

表格		
模型	基本原理	特点
K 近邻 (KNN)	基于距离度量的分类方法，通过投票选择最近邻的类别	无训练过程，简单直观，对数据分布无假设
朴素贝叶斯	基于贝叶斯定理和特征独立假设的概率模型	计算速度快，对小规模数据表现较好
逻辑回归	线性模型，通过 sigmoid 函数输出类别概率	可解释性强，适合线性可分数据
支持向量机 (SVM)	寻找最优超平面最大化类别间隔	对高维数据表现优秀，泛化能力强
决策树	基于特征阈值的树形结构分类模型	可解释性强，容易过拟合
随机森林	多棵决策树的集成学习方法	抗过拟合能力强，稳定性好

3. 模型评估指标

- 准确率 (Accuracy)：** 正确分类的样本数占总样本数的比例。
- 混淆矩阵 (Confusion Matrix)：** 展示模型在每个类别上的预测结果，可直观反映类别间的 误判情况。
- 错误样本分析：** 选取部分被错误分类的样本，分析误差产生的原因。

四、实验结果与分析

1. 不同模型准确率对比


本次实验中 6 种模型在测试集上的准确率如下表所示：

表格	
模型	测试准确率
KNN	0.9867
Naive Bayes	0.8311
Logistic Regression	0.9644
SVM	0.9911
Decision Tree	0.8800
Random Forest	0.9756

从结果可以看出，SVM 模型的测试准确率最高（99.11%），其次是 KNN 和随机森林；朴素贝叶斯模型的准确率最低（83.11%）。

2. 混淆矩阵（以 SVM 模型为例）

为了进一步分析模型的分类效果，选取表现最优的 SVM 模型绘制混淆矩阵，如下图所示：




从混淆矩阵可以看出：

模型对数字 0、1、2 的识别准确率接近 100%，几乎没有误判。

数字 5、8、9 存在少量误判，主要集中在形状相似的类别之间（如 5 和 6、8 和 1）。

3. 错误分类样本分析

本次实验中，SVM 模型在测试集上共产生 6 个错误分类样本，部分样本如下图所示：



通过分析错误样本可以发现，模型的误判主要集中在以下情况：

1. 笔画模糊、边缘不清晰的手写数字，特征区分度较低。
2. 形状高度相似的数字（如 8 和 1、5 和 6），模型难以区分。
3. 部分样本的灰度值分布不均匀，影响了模型对像素特征的判断。

4. 结果分析与讨论

基于距离度量的模型（SVM、KNN）在像素级特征的手写数字分类任务中表现最优，说明这类模型能够有效捕捉像素间的空间关系。

朴素贝叶斯模型表现较差，主要原因是其“特征独立”的假设不符合手写数字像素特征之间的强相关性。

决策树模型容易过拟合，在测试集上的表现不如集成学习方法（随机森林）

五、实验总结与改进建议

1. 实验总结

本次实验成功完成了手写数字分类任务,对比了 6 种传统机器学习模型的性能,验证了 SVM 模型在该任务中的优势,同时通过混淆矩阵和错误样本分析,明确了模型的误差来源。

2. 改进建议

- 特征优化:** 可以使用 HOG 等手工特征替代原始像素,提高模型对形状特征的提取能力。
- 模型调参:** 对 SVM、随机森林等模型的参数进行网格搜索,进一步提升准确率。
- 数据增强:** 通过旋转、平移等数据增强方法,提高模型对数字形变的鲁棒性。
- 模型融合:** 使用多个模型的集成学习方法,结合不同模型的优势,降低误判率。

六、思考题

思考题 1: 为什么在图像分类任务中,传统机器学习方法通常需要将图像转换为向量形式?
传统机器学习模型(如 KNN、SVM、逻辑回归等)的输入要求是**结构化的向量数据**,无法直接处理二维的图像矩阵。二维图像是(H, W, C)的矩阵,包含空间位置信息,而传统模型的数学公式(如距离计算、矩阵乘法)仅支持一维向量输入。将图像展平为向量(如 8×8→64 维),可以把每个像素值作为独立特征,直接输入模型进行计算。缺点是这种方式丢失了像素间的空间关系(如相邻像素的关联性),也无法处理图像的平移、旋转等形变。

思考题 2: 对比本次实验中不同模型的性能,分析它们的优缺点和适用场景。

表格

模型	优点	缺点	适用场景
KNN	无训练过程、实现简单、对数据分布无假设	计算量大、对高维数据效率低、易受噪声影响	小规模、低维数据的分类任务
朴素贝叶斯	训练速度快、对小规模数据友好	假设特征独立,不适合特征相关的图像数据	文本分类等特征独立性较强的任务
逻辑回归	可解释性强、训练速度快、支持多分类	只能处理线性可分数据,对复杂模式拟合能力弱	线性特征明显的二分类 / 多分类任务
SVM	泛化能力强、对高维数据表现优秀	训练速度慢、调参复杂、不适合大规模数据	小规模、高维特征的分类任务(如手写数字识别)
决策树	可解释性强、无需特征预处理	容易过拟合、对噪声敏感	小规模、低维数据的探索性分析
随机森林	抗过拟合能力强、稳定性好、鲁棒性高	模型可解释性差、训练速度慢	各类结构化数据分类任务,尤其是复杂非线性数据

思考题 3: 为什么原始像素特征在手写数字识别中表现尚可,但在复杂图像任务中效果不佳?

手写数字数据集的图像尺寸小(8×8)、背景干净、结构简单,像素特征足以区分不同数字的形状差异。在复杂图像任务中(如物体识别),原始像素存在以下局限:

- 丢失空间信息:** 展平为向量后,像素间的位置关系被破坏,无法捕捉物体的整体结构。
- 对形变敏感:** 图像的平移、旋转、缩放会直接改变像素值,导致特征失效。
- 维度灾难:** 高分辨率图像的像素向量维度极高,会导致模型训练困难、计算量爆炸。
- 噪声干扰:** 光照变化、背景噪声会直接影响像素值,降低模型鲁棒性。

思考题 4：本次实验中，哪些因素可能导致模型分类错误？如何改进？

主要误差来源：

1. 数据本身的问题：部分手写数字笔画模糊、形状不标准，与其他数字的特征高度相似（如 8 和 1、5 和 6）。
2. 特征的局限性：仅使用原始像素特征，无法有效提取数字的边缘、轮廓等关键形状信息。
3. 模型的局限性：部分模型（如朴素贝叶斯）的假设与图像数据分布不匹配，无法捕捉像素间的相关性。
4. 参数设置问题：模型未经过调参，可能存在欠拟合或过拟合的情况。

改进方法：

1. 特征优化：使用 HOG、SIFT 等手工特征，或使用 PCA 降维去除冗余信息。
2. 模型调参：对 SVM、随机森林等模型进行网格搜索，优化超参数。
3. 数据增强：通过旋转、平移、缩放等操作扩展训练数据，提高模型对形变的鲁棒性。
4. 模型选择：尝试集成学习或深度学习方法，进一步提升复杂模式的拟合能力。

思考题 5：混淆矩阵在模型评估中有什么作用？

混淆矩阵是评估分类模型性能的核心工具，作用包括：

1. 直观展示分类结果：清晰呈现每个类别的真实标签与预测标签的对应关系。
2. 识别易混淆类别：快速定位模型容易误判的类别（如本次实验中 5 和 6、8 和 1）。
3. 计算细分指标：可以基于混淆矩阵计算每个类别的精确率、召回率、F1 值，全面评估模型性能。
4. 指导模型优化：根据混淆矩阵的结果，针对性地对易混淆类别进行特征优化或数据增强。